

HIỂU ĐÚNG BẢN CHẤT CỐT LÕI CÂY QUYẾT ĐỊNH (DECISION TREES)

Bộ tài liệu phân tích trực quan toàn diện dựa trên đề bài tập về nhà "**Bài Tập: Decision Trees**". Đột phá với cấu trúc sơ phạm 6 bước: **Đề bài gốc** → **Ẩn dụ thực tế** → **Giải mã từng ký hiệu toán học** → **Câu nối dữ liệu** → **Lời giải với bước tính trung gian** → **Đúc kết thực chiến**. Không chỉ thế số bấm máy tính: Giúp người học bóc tách tại sao có dấu trừ, tại sao dùng $\log_2$, tại sao Gini lại bình phương xác suất, và tại sao cắt tỉa lại phạt thêm 0.5 lỗi!

1

Đề Bài Gốc

Nguyên văn đề bài và dữ liệu 14 mẫu chuẩn

2

Ẩn Dụ Thực Tế

Trò chơi 20 câu hỏi, thanh gạt nhiệt độ, cảnh thừa

3

Giải Mã Ký Hiệu

Hiểu từng số hạng: $\log_2$, dấu âm, bình phương Gini

4

Bước Tính Rõ Ràng

Không nhảy cóc: Hiển thị đầy đủ phép tính trung gian

BÀI 1 **Tính Toán Information Gain & Gain Ratio (ID3 & C4.5)****[ĐỀ BÀI GỐC]** **Bài Tập 1: Tính Toán Information Gain và Gain Ratio**

Cho tập dữ liệu dự đoán đi chơi tennis (Play) gồm 14 mẫu (9 Yes, 5 No) dựa trên: Outlook (Sunny, Overcast, Rain) và Humidity (High, Normal).
Yêu cầu: (a) Tính $H(S)$; (b) Tính $IG(S, Outlook)$; (c) Tính $IG(S, Humidity)$; (d) Tính SplitInfo và Gain Ratio cho Outlook; (e) Thuộc tính nào nên được chọn để tách nút gốc? Giải thích ngắn gọn.

[GIẢI MÃ CÔNG THỨC] **Tại sao Entropy lại là: $H(S) = - \sum p_i \log_2(p_i)$?**

- **$\log_2(1/p) = -\log_2(p)$ là gì?** Đo "độ bất ngờ" (lượng thông tin tính bằng bit nhị phân). Biến cố chắc chắn xảy ra ($p=1$) thì $\log_2(1) = 0$ bit (không bất ngờ). Biến cố càng hiếm thì khi xảy ra ta càng bất ngờ (nhiều bit).
- **Tại sao nhân thêm p ?** Lấy trung bình theo tần suất xuất hiện mỗi ngày.
- **Tại sao có dấu trừ (-)?** Vì $p \leq 1$ nên $\log_2(p)$ luôn âm! Dấu trừ đứng trước triệt tiêu dấu âm để Entropy luôn dương.

[ẢNH DỤ THỰC TẾ] **Trò Chơi 20 Câu Hỏi & Chiếu Vé Phạt Câu Hỏi Gian Lận**

- **Information Gain (IG):** Lượng mù mờ giảm đi sau khi hỏi: $IG = H(\text{ban đầu}) - H(\text{còn lại})$.
- **Gain Ratio:** Phạt câu hỏi băm quá nhiều nhánh nhỏ vô nghĩa (như hỏi số CCCD). Mẫu số SplitInfo đo mức độ băm nhỏ để dim điểm gian lận!

1. Bóc Tách Dữ Liệu 14 Mẫu (Play: 9 Yes, 5 No)

Outlook	Yes	No	Tổng	Phép tính Entropy nhánh $H(S_v)$	Humidity	Yes	No	Tổng	Phép tính Entropy nhánh $H(S_v)$
Sunny	2	3	5	$-(2/5)\log_2(2/5) - (3/5)\log_2(3/5) = \mathbf{0.9710}$	High	3	4	7	$-(3/7)\log_2(3/7) - (4/7)\log_2(4/7) = \mathbf{0.9852}$
Overcast	4	0	4	100% Yes $\rightarrow H = 0.0000$ (Tinh khiết)	Normal	6	1	7	$-(6/7)\log_2(6/7) - (1/7)\log_2(1/7) = \mathbf{0.5917}$
Rain	3	2	5	$-(3/5)\log_2(3/5) - (2/5)\log_2(2/5) = \mathbf{0.9710}$	Tổng mẫu			14	—

2. Lời Giải Với Đầy Đủ Bước Tính Trung Gian**a. Entropy ban đầu $H(S)$ — Hiển thị rõ giá trị logarit từng lớp:**

- Lớp Yes ($9/14 \approx 0.6429$): $\log_2(9/14) \approx -0.6374 \rightarrow (9/14) \times (-0.6374) = \mathbf{-0.4098}$.
- Lớp No ($5/14 \approx 0.3571$): $\log_2(5/14) \approx -1.4854 \rightarrow (5/14) \times (-1.4854) = \mathbf{-0.5305}$.

$$H(S) = - [(-0.4098) + (-0.5305)] = - [-0.9403] = \mathbf{0.9403 \text{ bit}}$$

b. $IG(S, Outlook)$ — Nhân trọng số từng nhánh:

$$H(S|Outlook) = (5/14) \times 0.9710 + (4/14) \times 0 + (5/14) \times 0.9710 = 0.3468 + 0 + 0.3468 = \mathbf{0.6935}.$$

$$IG = 0.9403 - 0.6935 = \mathbf{0.2468 \text{ bit}}$$

c. $IG(S, Humidity)$ — Nhân trọng số từng nhánh:

$$H(S|Humidity) = (7/14) \times 0.9852 + (7/14) \times 0.5917 = 0.4926 + 0.2959 = \mathbf{0.7885}.$$

$$IG = 0.9403 - 0.7885 = \mathbf{0.1518 \text{ bit}}$$

d. SplitInfo & Gain Ratio (Outlook):

SplitInfo đo mức độ băm vụn 14 mẫu thành 3 nhóm (5, 4, 5):
 $\text{SplitInfo} = - [2 \times (5/14) \log_2(5/14) + (4/14) \log_2(4/14)] = - [-1.0610 - 0.5164] = \mathbf{1.5774}.$

$$\text{GainRatio(Outlook)} = \frac{0.2468}{1.5774} = \mathbf{0.1565}$$

e. Lựa chọn thuộc tính tách nút gốc:

$$\text{SplitInfo(Humidity)} = - 2 \times (7/14) \log_2(7/14) = \mathbf{1.0000}.$$

$$\text{GainRatio(Humidity)} = 0.1518 / 1.0 = \mathbf{0.1518}.$$

So sánh: **GainRatio(Outlook) = 0.1565 > GainRatio(Humidity) = 0.1518.**

→ **Chọn Outlook làm nút gốc!**

[ĐÚC KẾT THỰC CHIẾN] **Tại sao C4.5 vượt trội hơn ID3?**

ID3 luôn bị cám dỗ chọn các thuộc tính có nhiều nhánh rẽ (như Ngày, Số điện thoại). C4.5 dùng Gain Ratio để lấy IG chia cho SplitInfo, giúp loại bỏ thuộc tính rẽ nhánh vụn vặt và chống Overfitting.

BÀI 2

Xác Định Ngưỡng Tối Ưu Cho Thuộc Tính Liên Tục

ĐỀ BÀI GỐC

Bài Tập 2: Xác định Ngưỡng Tối Ưu cho Thuộc Tính Liên Tục
Cho thuộc tính liên tục Temperature và nhãn Play gồm 14 mẫu: (64,No), (65,No), (68,Yes), (69,Yes), (70,Yes), (71,Yes), (72,No), (75,Yes), (80,Yes), (81,Yes), (83,No), (85,Yes), (86,No), (90,No). Tổng: 6 No, 8 Yes.
Yêu cầu: (a) Sắp xếp và liệt kê ngưỡng tiềm năng; (b) Tính IG cho T = 75; (c) So sánh T = 72.5 và T = 77.5 ngưỡng nào cho IG cao hơn mà không cần tính đầy đủ; (d) Tính Gain Ratio cho T = 75 nếu SplitInfo = 0.8.

GIẢI MÃ BÀN CHẤT

Định lý Ranh Giới (Fayyad & Irani)

- **Tại sao ngưỡng cắt là $(v_i + v_{i+1})/2$?** Giữa 2 giá trị liên tục, điểm chính giữa là đường phân cách nhị phân công bằng nhất.
- **Tại sao chỉ cần xét các điểm ĐỐI NHÃN?** Nếu 2 giá trị liên tiếp cùng là Yes (ví dụ 75 Yes và 80 Yes), nhất cắt đặt ở giữa sẽ chỉ chia tách tập Yes thành 2 nửa Yes, không hề làm tăng độ tinh khiết! Ngưỡng tối ưu bắt buộc phải nằm ở ranh giới giữa Yes và No.

ẢNH DỤ THỰC TẾ

Vạch Đo Nhiệt Kế & Lát Cắt Thông Minh
Giống như bác sĩ chọn vạch 37.5° để phân loại sốt và không sốt: Ta chỉ tìm vạch cắt ở nơi có sự biến chuyển triệu chứng, không ai đi đặt vạch cắt giữa 2 người cùng sốt 39° và 40°!

1. Sắp Xếp Dữ Liệu & Xác Định Ranh Giới Chuyển Đổi Nhãn

Giá trị	64	65		68	69	70	71		72		75	80	81		83		85		86	90
Nhãn	No	No	→	Yes	Yes	Yes	Yes	→	No	→	Yes	Yes	Yes	→	No	→	Yes	→	No	No

2. Lời Giải Chi Tiết

a. Liệt kê các ngưỡng tiềm năng:

- Tất cả 13 ngưỡng: 64.5, **66.5***, 68.5, 69.5, 70.5, **71.5***, **73.5***, 77.5, 80.5, **82.0***, **84.0***, **85.5***, 88.0.
- Các **ngưỡng đổi nhãn (*)** mang giá trị phân loại thật sự: **66.5, 71.5, 73.5, 82.0, 84.0, 85.5**.

b. Tính Information Gain cho ngưỡng T = 75 (≤ 75 và > 75) — Từng bước chi tiết:

- Toàn bộ 14 mẫu (8 Yes, 6 No): $H(S) = - (8/14)\log_2(8/14) - (6/14)\log_2(6/14) = - (-0.4613 - 0.5239) = \mathbf{0.9852}$.
- Nhánh Trái (≤ 75 gồm 8 mẫu: 5 Yes, 3 No): $H_{\text{trái}} = - (5/8)\log_2(5/8) - (3/8)\log_2(3/8) = - (-0.4238 - 0.5306) = \mathbf{0.9544}$.
- Nhánh Phải (> 75 gồm 6 mẫu: 3 Yes, 3 No): $H_{\text{phải}} = - (3/6)\log_2(3/6) - (3/6)\log_2(3/6) = \mathbf{1.0000}$ (cân bằng 50-50).
- Entropy sau khi tách: $H(S|T=75) = (8/14) \times 0.9544 + (6/14) \times 1.0000 = 0.5454 + 0.4286 = \mathbf{0.9740}$.

$IG(S, \text{Temperature}@T=75) = H(S) - H(S|T=75) = 0.9852 - 0.9740 = \mathbf{0.0112 \text{ bit}}$

c. So sánh T = 72.5 và T = 77.5 (Không cần tính số):

- **T = 72.5:** Nằm tại ranh giới chuyển nhãn 72(No) và 75(Yes). Nhánh phải cô lập được chuỗi Yes thuần khiết (75, 80, 81), làm giảm mạnh entropy!
- **T = 77.5:** Nằm giữa 75(Yes) và 80(Yes). Cả 2 phía đều là Yes, chia cắt vô bổ một nhóm đồng nhất.

→ Kết luận: Ngưỡng T = 72.5 chắc chắn cho IG cao hơn T = 77.5!

d. Tính Gain Ratio cho T = 75:
Biết $\text{SplitInfo}(S, \text{Temperature}@T=75) = 0.8$:

$$\text{GainRatio} = \frac{IG}{\text{SplitInfo}} = \frac{0.0112}{0.8} = \mathbf{0.0140}$$

ĐÚC KẾT THỰC CHIẾN

Bí quyết tối ưu của LightGBM & CatBoost:
Khi làm việc với hàng triệu dòng dữ liệu số liên tục, thuật toán không bao giờ duyệt hết mọi giá trị mà dùng histogram chia bin và chỉ kiểm tra các điểm đổi nhãn, giúp tiết kiệm 95% tài nguyên tính toán.

Tài liệu tự học trực quan Học Máy • Decision Trees

schedule-smart • docs/9.More/

BÀI 3 Phân Tích Rẽ Nhánh & Tính Toán Gini Index (CART)

[ĐỀ BÀI GỐC] Bài Tập 3: Phân tích Rẽ nhánh và Tính toán Gini Index

Xét một nút trong cây quyết định chứa 20 samples với phân phối lớp: [5, 15] (lớp 0: 5, lớp 1: 15). Phép tách nhị phân tạo ra hai nút con:

• Nút con trái: 8 samples, phân phối [4, 4] | • Nút con phải: 12 samples, phân phối [1, 11].

Yêu cầu: (a) Tính Gini nút cha; (b) Tính Gini con trái và con phải; (c) Tính mức giảm Gini Impurity (ΔGini); (d) Đánh giá phép tách này có tốt không? Giải thích.

[GIẢI MÃ BÀN CHẤT] Tại sao Gini lại là: $\text{Gini} = 1 - \sum p_i^2$?

- **Bình phương xác suất p_i^2 là gì?** Thò tay vào rổ bốc 1 quả, ghi nhận màu, bỏ lại, bốc tiếp quả 2. Xác suất để cả 2 lần đều bốc trúng màu i là: $p_i \times p_i = p_i^2$.
- **Tổng $\sum p_i^2 = p_0^2 + p_1^2$ là gì?** Là xác suất bốc được 2 quả CÙNG MÀU.
- **Tại sao lấy 1 trừ đi?** $1 - \sum p_i^2$ chính là xác suất bốc phải 2 quả KHÁC MÀU (bốc phải sự nhầm lẫn, vẩn đục). Nếu rổ 100% cùng 1 màu $\rightarrow \text{Gini} = 0$ (tinh khiết tuyệt đối).

[LẤN DỤ THỰC TẾ] Máy Lọc Nước & Phép Tách Thuần Khiết

Gini đo "độ đục" của nước. Nhát cắt rẽ nhánh giống như một màng lọc: Nước sau khi qua màng lọc càng trong vắt (Gini càng giảm sâu về 0) thì màng lọc đó càng xịn!

1. Bảng Chi Tiết Tần Suất & Xác Suất Trước / Sau Tách

Nút	Mẫu	Lớp 0	Lớp 1	Tỉ lệ (p_0, p_1)	Xác suất cùng màu ($p_0^2 + p_1^2$)	$\text{Gini} = 1 - \sum p_i^2$
Nút Cha	20	5	15	$p_0 = 0.25, p_1 = 0.75$	$0.25^2 + 0.75^2 = 0.0625 + 0.5625 = 0.6250$	$1 - 0.6250 = \mathbf{0.3750}$ (3/8)
Con Trái	8	4	4	$p_0 = 0.50, p_1 = 0.50$	$0.50^2 + 0.50^2 = 0.2500 + 0.2500 = 0.5000$	$1 - 0.5000 = \mathbf{0.5000}$ (Đục tối đa)
Con Phải	12	1	11	$p_0 = 1/12, p_1 = 11/12$	$(1/12)^2 + (11/12)^2 = 1/144 + 121/144 = 122/144$	$1 - 122/144 = \mathbf{0.1528}$ (Rất trong)

2. Lời Giải Chi Tiết

a. Gini Index của nút cha:

$$\text{Gini}(\text{Cha}) = 1 - [(5/20)^2 + (15/20)^2] = 1 - [0.0625 + 0.5625] = 1 - 0.6250 = \mathbf{0.3750}$$

b1. Gini Con Trái (8 mẫu [4, 4]):

$$\text{Gini}_L = 1 - [0.5^2 + 0.5^2] = 1 - 0.50 = \mathbf{0.5000}$$

b2. Gini Con Phải (12 mẫu [1, 11]):

$$\text{Gini}_R = 1 - \left[\frac{1}{144} + \frac{121}{144} \right] = \frac{22}{144} \approx \mathbf{0.1528}$$

c. Mức độ giảm Gini Impurity (ΔGini) — Trọng số từng nhánh:

- Gini trung bình sau tách: $\text{Gini}_{\text{split}} = (8/20) \times \text{Gini}_L + (12/20) \times \text{Gini}_R = 0.4 \times 0.5000 + 0.6 \times 0.1528 = 0.2000 + 0.0917 = \mathbf{0.2917}$.

$$\Delta\text{Gini} = \text{Gini}(\text{Cha}) - \text{Gini}_{\text{split}} = 0.3750 - 0.2917 = \mathbf{0.0833}$$
 (chính xác bằng phân số 1/12)

d. Đánh giá: Phép tách này có tốt không?

- **Ưu điểm:** $\Delta\text{Gini} > 0$ chứng minh độ tinh khiết có tăng. Nhánh phải rất xuất sắc khi gom được 11/12 mẫu Lớp 1 (đạt độ thuần khiết 91.7%, Gini giảm sâu về 0.1528), giúp mô hình tự tin ra quyết định Lớp 1.
 - **Nhược điểm:** Nhánh trái rơi vào bế tắc (tỷ lệ 4:4, Gini = 0.5), bắt buộc phải tách tiếp ở tầng sau.
- **Kết luận:** Đây là phép tách **khá tốt** vì đã cô lập thành công phần lớn Lớp 1 vào một nhánh thuần khiết.

[ĐÚC KẾT THỰC CHIẾN] Tại sao thư viện Scikit-Learn chọn Gini làm mặc định?

Gini chỉ gồm phép cộng trừ và bình phương đơn giản (CPU tính trong 1 chu kỳ), trong khi Entropy bắt buộc phải tính hàm $\log_2$ (tốn hàng chục chu kỳ CPU). Gini giúp Scikit-Learn huấn luyện cây nhanh hơn gấp 3-5 lần mà độ chính xác chênh lệch dưới 1%.

BÀI 4 Đánh Giá Pruning Sử Dụng Lỗi Pessimistic (C4.5)

[ĐỀ BÀI GỐC] Bài Tập 4: Đánh giá Pruning sử dụng Lỗi Pessimistic

Một nút t có 20 samples, phân phối lớp [13, 7] (Lớp A: 13, Lớp B: 7). Cây con dưới nút t có 2 lá:

• Lá 1: 10 samples, phân phối [8, 2] | • Lá 2: 10 samples, phân phối [5, 5].

Công thức đơn giản hóa: **Lỗi pessimistic = Lỗi quan sát được + 0.5 × (Số lá).**

Yêu cầu: (a) Tính lỗi quan sát nếu không cắt tỉa; (b) Tính lỗi quan sát nếu có cắt tỉa; (c) Áp dụng ước tính pessimistic; (d) Quyết định cắt tỉa hay không? Giải thích.

[GIẢI MÃ BÀN CHẤT] Tại sao lại phạt thêm "+ 0.5 cho mỗi chiếc lá"?

• **Cạm bẫy lạc quan (Optimistic bias):** Trên tập huấn luyện, bạn càng vẽ thêm nhiều cành lá thì số lỗi nhìn thấy càng ít (học vẹt).

• **Hình phạt bi quan (Pessimistic penalty):** Tác giả C4.5 giả định rằng trên dữ liệu thực tế tương lai, mỗi chiếc lá con mọc thêm sẽ có nguy cơ gây thêm 0.5 lỗi ngẫu nhiên. Nếu mọc thêm lá mà không giảm bớt được lỗi thực tế thì tổng điểm phạt sẽ tăng lên → Phải vung dao cắt tỉa!

[ẤN DỤ THỰC TẾ] Dao Cạo Occam: "Đừng Thêm Chi Tiết Khi Không Cần Thiết"

Giống như thiết kế bộ máy doanh nghiệp: Nếu lập thêm một phòng ban mới mà doanh thu và năng suất không hề tăng, thì phòng ban đó chỉ làm tốn thêm chi phí quản lý vận hành. Cắt giảm phòng ban thừa là quyết định sáng suốt nhất!

1. Bảng So Sánh Hai Kịch Bản Trước & Sau Cắt Tỉa

Kịch Bản	Cấu Trúc	Quy Tắc Quyết Định	Số Lỗi Quan Sát (E)	Phạt Lá (0.5 × L)	Tổng Lỗi Pessimistic
Không Cắt Tỉa (Giữ 2 lá con)	2 Lá (L = 2): Lá 1: [8A, 2B] Lá 2: [5A, 5B]	Lá 1 bầu đa số A (sai 2 mẫu B) Lá 2 bầu đa số A/B (sai 5 mẫu)	E = 2 + 5 = 7 lỗi	2 × 0.5 = 1.0 lỗi phạt	7 + 1.0 = 8.0 lỗi
Có Cắt Tỉa (Thu về 1 lá t)	1 Lá (L = 1): Nút t: [13A, 7B]	Nút t bầu đa số A (sai 7 mẫu B)	E = 7 lỗi	1 × 0.5 = 0.5 lỗi phạt	7 + 0.5 = 7.5 lỗi

2. Lời Giải Chi Tiết

a. Lỗi quan sát khi KHÔNG cắt tỉa (giữ 2 lá):

- Lá 1 (8A, 2B): Đoán nhãn A → Sai **2** mẫu.
- Lá 2 (5A, 5B): Đoán nhãn A hoặc B → Sai **5** mẫu.

$$E_{\text{subtree}} = 2 + 5 = \mathbf{7 \text{ lỗi}}$$

b. Lỗi quan sát khi CÓ cắt tỉa (thu về 1 lá t):

Nút t có 20 mẫu (13A, 7B). Biểu quyết đa số gán nhãn dự đoán là A → Sai 7 mẫu thuộc lớp B.

$$E_{\text{pruned}} = 20 - 13 = \mathbf{7 \text{ lỗi}}$$

c. Áp dụng công thức ước tính Pessimistic:

- Giữ cây con (gồm L = 2 lá): $Lỗi_{\text{pessimistic}}(\text{subtree}) = 7 + (2 \times 0.5) = 7 + 1.0 = \mathbf{8.0 \text{ lỗi}}$.
- Cắt tỉa thành 1 lá (L = 1 lá): $Lỗi_{\text{pessimistic}}(\text{pruned}) = 7 + (1 \times 0.5) = 7 + 0.5 = \mathbf{7.5 \text{ lỗi}}$.

d. Quyết định & Giải thích bản chất:

So sánh: $Lỗi_{\text{pessimistic}}(\text{pruned}) = 7.5 < Lỗi_{\text{pessimistic}}(\text{subtree}) = 8.0$.

→ **QUYẾT ĐỊNH: NÊN CẮT TỈA (PRUNE)!**

Giải thích bản chất: Trên dữ liệu huấn luyện, việc mọc thêm 2 lá không làm giảm được bất kỳ lỗi nào (đều sai 7 mẫu). Việc duy trì 2 lá chỉ làm tăng nguy cơ học vẹt (Overfitting). Công thức Pessimistic phạt thẳng tay 2 chiếc lá này (phạt 1.0 lỗi), khiến phương án cắt tỉa (chỉ phạt 0.5) chiến thắng!

[ĐÚC KẾT THỰC CHIẾN] Điểm độc đáo của Pessimistic Pruning trong C4.5:

Thông thường để cắt tỉa bạn cần chia riêng một tập kiểm định (Validation set). C4.5 không cần tập Validation mà dùng ngay công thức phạt thống kê Pessimistic này trên tập huấn luyện, cực kỳ quý giá khi dữ liệu ít.

BÀI 5 Cắt Tỉa Độ Phức Tạp Chi Phí Cost-Complexity (CART)

[ĐỀ BÀI GỐC] Bài Tập 5: Tính Toán Cost-Complexity Pruning (CART)

Cho cây quyết định T có lỗi huấn luyện $R(T) = 25$, số lá $|T| = 10$.

Yêu cầu: (a) Viết biểu thức $R_\alpha(T)$; (b) Tính $R_\alpha(T)$ cho $\alpha = 0.5$ và $\alpha = 2.0$; (c) Cắt tỉa tạo ra cây T' có $R(T') = 30$ và $|T'| = 4$. Với $\alpha = 2.0$, nên giữ cây gốc T hay chọn T' ? (d) Ý nghĩa của việc tăng giá trị α .

[GIẢI MÃ BÀN CHẤT] Ý nghĩa hàm chi phí: $R_\alpha(T) = R(T) + \alpha |T|$

- $R(T)$:** Chi phí sai số (số mẫu đoán sai trên tập huấn luyện).
- $|T|$:** Chi phí cồng kềnh (số lượng lá của cây).
- α (Complexity Parameter):** "Mức thuế tính trên mỗi chiếc lá". Cân bằng giữa việc giảm lỗi sai và giữ cho cây nhỏ gọn.

[ẢNH DƯỠNG THỰC TẾ] Chi Phí Thuê Mặt Bằng Chi Nhánh & Bài Toán Đóng Cửa

Giữ 10 chi nhánh ($|T|=10$) thì phục vụ sát từng khách hơn (chỉ sai 25 đơn hàng), nhưng tiền thuê mặt bằng rất tốn ($\alpha \times 10$). Khi tiền thuê tăng vọt ($\alpha=2.0$), chấp nhận đóng bớt 6 chi nhánh để tổng chi phí là thấp nhất!

1. Lời Giải Chi Tiết

a. Biểu thức tính hàm chi phí độ phức tạp $R_\alpha(T)$:

$$R_\alpha(T) = R(T) + \alpha \times |T|$$

b1. Tính với $\alpha = 0.5$ (Thuế nhẹ):

$$R_{0.5}(T) = 25 \text{ (lỗi)} + 0.5 \times 10 \text{ (phạt lá)} = 25 + 5 = \mathbf{30.0}.$$

b2. Tính với $\alpha = 2.0$ (Thuế nặng):

$$R_{2.0}(T) = 25 \text{ (lỗi)} + 2.0 \times 10 \text{ (phạt lá)} = 25 + 20 = \mathbf{45.0}.$$

c. So sánh cây gốc T và cây cắt tỉa T' khi $\alpha = 2.0$:

- Cây gốc T: $R_{2.0}(T) = 25 + 2.0 \times 10 = \mathbf{45.0}$.
- Cây cắt tỉa T' : $R_{2.0}(T') = 30 + 2.0 \times 4 = 30 + 8 = \mathbf{38.0}$.

$$\text{So sánh: } R_{2.0}(T') = 38.0 < R_{2.0}(T) = 45.0 \rightarrow \text{Chọn cây đã cắt tỉa } T'!$$

Bản chất: Dù T' tăng thêm 5 lỗi (từ 25 lên 30), nhưng tiết kiệm được hẳn 6 lá (từ 10 xuống 4), giúp giảm được $6 \times 2 = 12$ điểm phạt. Lợi ích tinh gọn (12) áp đảo chi phí sai số (5)!

d. Ý nghĩa của việc tăng giá trị α :

- $\alpha = 0$: Không phạt lá $\rightarrow$ giữ cây to nhất, cố học vẹt để ép lỗi train về cực tiểu (Overfitting).
- α càng tăng: Phạt lá càng nặng $\rightarrow$ ép thuật toán phải cắt tỉa mạnh tay, tạo ra các cây nhỏ gọn, tăng tính tổng quát hóa trên dữ liệu mới. Nếu $\alpha \rightarrow \infty$, cây sẽ bị tỉa chỉ còn 1 nút gốc duy nhất.

2. Bảng Tra Cứu Nhanh 5 Dạng Bài Decision Trees (Master Cheatsheet)

Chủ Đề	Thuật Toán	Công Thức Trọng Tâm	Bản Chất & Nguyên Tắc Ứng Dụng
Information Gain & Ratio	ID3 / C4.5	$IG = H(S) - H(S A)$ $GR = IG / \text{SplitInfo}$	Dùng Gain Ratio để phạt các thuộc tính băm vụn dữ liệu thành quá nhiều nhánh.
Thuộc Tính Liên Tục	C4.5 / CART	$T = (v_i + v_{i+1}) / 2$	Định lý Fayyad & Irani: Chỉ cần xét các điểm đổi nhãn để tiết kiệm 95% thời gian tính.
Gini Impurity	CART	$Gini = 1 - \sum p_i^2$	Xác suất bốc phải 2 phần tử khác màu. Tính nhanh gấp nhiều lần Entropy vì không dùng log ₂ .
Pessimistic Pruning	C4.5	Lỗi = Quan sát + $0.5 \times L$	Phạt thêm 0.5 lỗi cho mỗi lá để phát hiện các cành thừa không giúp ích cho phân loại.
Cost-Complexity Pruning	CART (Scikit-Learn)	$R_\alpha(T) = R(T) + \alpha T $	Dùng Cross-Validation quét tìm α (ccp_alpha) tối ưu nhất để cân bằng giữa lỗi và số lá.